

Curso de Ciência de Dados, Machine Learning, Deep Learning e IA generativa com uso de LLMs

Disciplina: Visão Computacional e IA Generativa

Professor(a): João Macedo

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Generalidades sobre IA

- Aprendizado de máquina (ML) e AI têm uma relação íntima
- ML = algoritmos e modelos estatísticos usados em AI pelo computador para realizar uma tarefa sem usar instruções explícitas, confiando em padrões e inferência aprendidos a partir dos dados estatísticos.
- Ideia é deixar a máquina aprender as regras necessárias para realizar uma tarefa a partir dos dados estatísticos.
- Como aprender dos dados?
- Depende da tarefa.
- AI escolheu algumas tarefas simples iniciais, tentou resolvê-las. Em seguida, generalizar e escalar
- Grande sucesso

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Classificação supervisionada

Nesse contexto, supervisionado pode ser interpretado como sinônimo de rotulado. Exemplo: treinamento de um método para clasificar imagens como “contendo carro” ou “não contendo carro” (**classificação binária**).



0 - Sem carro



1 - com carro

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Classificação supervisionada

Importância da qualidade do dataset.

Importância de conhecer condições de ambiente de produção.

Compare as imagens anteriores com essas abaixo.

O que poderia dar errado?



Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Classificação supervisionada

Exemplo multiclasse:



Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning


Classificação supervisionada

- Mais Exemplos:

- Duas espécies de flor

- 1 = Iris Versicolor

- 0 = Iris Setosa



- Usuários de um site

- 1 = clicam num anúncio

- 0 = não clicam



Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

De onde aprendemos

- Coletamos amostras estatísticas de instâncias dos objetos das duas populações
- Sinônimos: instâncias, itens, exemplos, casos, indivíduos, observações
- Conjunto de exemplos = amostra
- Em cada exemplo, medimos um conjunto de n **variáveis** ou **features** *em cada um deles*

$$\mathbf{X} = (X_1, X_2, \dots, X_n)$$

- Com base nas medições em $\mathbf{X}$ queremos aprender a distinguir os objetos dos dois grupos
- Anotamos também o verdadeiro rótulo associado a cada instância: classe 0 ou 1
- Este **rótulo (label)** é denotado por Y

$$(Y, \mathbf{X}) = (Y, X_1, X_2, \dots, X_n)$$

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

De onde aprendemos

- Novos itens chegam COM as n variáveis X 's mas SEM o rótulo Y
- Objetivo: construir uma regra de classificação para esses novos itens
- Com base nas n variáveis X 's, obter uma função matemática que prediga a classe do

$$\mathbf{X}^{\text{item}} = (X_1, X_2, \dots, X_n) \longrightarrow \text{Classificador} \longrightarrow \sigma(\mathbf{X}) = \mathbb{P}(Y = 1 | \mathbf{X})$$

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Dataset e Tarefa

Item	Classe Y	Variáveis/Features				Classificador $g(X_1, \dots, X_n) = \mathbb{P}(Y = 1 X)$
		X_1	X_2	...	X_n	
1	0	X_{11}	X_{12}	...	X_{1n}	0.07
2	0	X_{21}	X_{22}	...	X_{2n}	0.15
3	0		$\vdots$			$\vdots$
$\vdots$	$\vdots$		$\vdots$			$\vdots$
m_0	0	$X_{m_0,1}$	$X_{m_0,2}$	...	$X_{m_0,n}$	0.11
1	1	$X_{m_0+1,1}$	$X_{m_0+2,2}$	...	$X_{m_0+1,n}$	0.85
2	1	$X_{m_0+2,1}$	$X_{m_0+2,2}$	...	$X_{m_0+2,n}$	0.79
$\vdots$	$\vdots$		$\vdots$			$\vdots$
m_1	1	$X_{m_0+m_1,1}$	$X_{m_0+m_1,2}$	...	$X_{m_0+m_1,n}$	0.93
Novo Item	?	X_1^*	X_2^*	...	X_n^*	$g(X_1^*, \dots, X_n^*) = 0.09$

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Abordagem

- Abordagem geral de ML:
 - colete muitos exemplos do que se deseja classificar
 - Em cada exemplo, obtenha a sua verdadeira classe (label Y)
 - Em cada exemplo, obtenha longa lista de features (variáveis em X) que potencialmente afetam ou determinam a classe Y
 - Use criatividade, matemática e capacidade de processamento para rodar algoritmo que seja uma boa aproximação da regra ótima (regra de Bayes)

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Algoritmos de IA


- Todos os algoritmos são tentativas de aproximar-se do ótimo (regra de Bayes)
 - SVM,
 - Regressão Logística,
 - Redes Neurais,
 - Modelos Gráficos Probabilísticos (redes Bayesianas)
 - Árvores de Classificação,
 - Florestas Aleatórias,
 - Boosting,
 - Gradient Boosting, etc...

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Classificação não supervisionada

Exemplo clássico: clusterização (Nearest Neighbour e KNN)



Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Perceptron

Um perceptron é um modelo simples de neurônio artificial usado para classificação binária.

Ele recebe um conjunto de entradas $x_1, x_2, \dots, x_n$ - cada uma associada a um peso $w_1, w_2, \dots, w_n$. Esses pesos representam a importância de cada entrada para a decisão do modelo.

O primeiro passo é calcular a combinação linear das entradas e dos pesos, que chamaremos de **z**. A essa soma adicionamos um *bias* **b**, que é o termo constante que desloca o limite de decisão do modelo:

$$z = \sum_{i=1}^n w_i x_i + b$$

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Perceptron

O termo $z = \sum_{i=1}^n w_i x_i + b$ é passado por uma **função de ativação**,

gerando assim o valor final.


No perceptron clássico, usa-se uma função degrau (SIGN), que produz o valor 1 se z for maior que um limiar (geralmente 0), ou 0, caso contrário.

$$y = \text{SIGN}(z) = \begin{cases} 1 & \text{se } z > 0 \\ 0 & \text{se } z \leq 0 \end{cases}$$


Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Perceptron (visualização)






Função degrau (SIGN)



Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Perceptron (outras visualizações)



Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Redes Multilayer Perceptron (MLP)

Combinando vários perceptrons

Uma rede MLP é um tipo de rede neural artificial composta que combina múltiplas camadas de perceptrons.

A rede é organizada em camadas:

- Camada de entrada: recebe os dados.

- Camadas ocultas (ou hidden layers): realizam operações intermediárias.


- Camada de saída (output): produz a predição final.

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Redes Multilayer Perceptron (MLP)


Visualização:



Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning



Redes Multilayer Perceptron (MLP)



Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Redes Multilayer Perceptron (MLP)



Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Redes Multilayer Perceptron (MLP)

O Aprendizado

Nos slides a seguir, faremos diversas simplificações para descrever o processo de treinamento de uma rede neural.

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Redes Multilayer Perceptron (MLP)

O Aprendizado

O aprendizado em uma rede MLP (Multilayer Perceptron) é denominado de treinamento. Pressupõe a existência de um conjunto de elementos de entrada para os quais sabemos o rótulo correto.

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Redes Multilayer Perceptron (MLP)

O Aprendizado

O treinamento consiste em ajustar os pesos e bias da rede para que ela produza saídas cada vez mais próximas dos valores desejados. Em outras palavras, o que a rede aprende são os parâmetros (pesos e bias) que definem as transformações aplicadas aos dados de entrada.

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Redes Multilayer Perceptron (MLP)

O Aprendizado

Antes de iniciar o treinamento, os pesos e bias são inicializados com valores pequenos.

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Redes Multilayer Perceptron (MLP)

O Aprendizado

Forward pass

Quando uma entrada x é fornecida à rede, ocorrem os processos de cálculos “dos z e h que compõem a rede”, começando nas primeiras camadas até a

produção da saída (a predição da rede)

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Redes Multilayer Perceptron (MLP)

O Aprendizado

Forward pass

Uma rede projetada para classificar a raça a partir de dados [altura, comprimento, peso, idade] coletados de cachorros das raças “poodle”, “beagle” ou “caramelo” como poderá inicialmente gerar uma saída (provavelmente incorreta) para o primeiro x

[2.2, 0.7, 0.6]

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Redes Multilayer Perceptron (MLP)

O Aprendizado

Forward pass

A saída gerada: [2.2, 1.1, 0.6] - também denominada **scores** ou **logits**, representa a "preferência" bruta do modelo por cada classe.

É possível transformar em probabilidades aplicando Softmax, gerando [0.65, 0.22, 0.13]. Interpretação: probabilidades das “raças” $p(\text{raça}|x)$

[$p(\text{poodle}|x)$, $p(\text{beagle}|x)$, $p(\text{caramelo}|x)$]

(o somatório das probabilidades é 1.0)

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Redes Multilayer Perceptron (MLP)

O Aprendizado

A saída da rede é denominada **predição**.

Como conhecemos o rótulo das entradas de treino, definimos então uma função para quantificar o erro da rede para aquele exemplo, comparando a predição com o rótulo correto.

Essa função especial é denominada:

função de perda (loss function)

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Redes Multilayer Perceptron (MLP)

O Aprendizado - atualizando os pesos e bias

O processo de treinamento tem como objetivo **minimizar a loss function**, e para isso a rede utiliza o algoritmo de **backpropagation** combinado com **gradiente descendente**.

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Redes Multilayer Perceptron (MLP)

O Aprendizado - atualizando os pesos e bias

O algoritmo de **backpropagation** calcula como erro depende de cada peso e bias da rede, e os parâmetros da rede (pesos e bias) são atualizados (corrigidos) da camada de saída para as camadas anteriores, de acordo com a **taxa de aprendizado** (learning rate) predefinida.

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Redes Multilayer Perceptron (MLP)

O Aprendizado - atualizando os pesos e bias

O método **Stochastic Gradient Descent (SGD)** é uma variação do gradiente descendente usada para tornar o treinamento mais eficiente.

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Redes Multilayer Perceptron (MLP)

O Aprendizado - atualizando os pesos e bias

No gradiente descendente tradicional, o gradiente é calculado usando todo o conjunto de dados de treinamento antes de atualizar os parâmetros. Isso pode ser muito custoso quando o dataset é grande. O SGD, por outro lado, atualiza os parâmetros usando apenas um exemplo de treinamento por vez (ou pequenos grupos chamados mini-batches).

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Funções de Erro

Conceito

As funções de erro (loss functions) medem a diferença entre as previsões do modelo e os valores reais. Elas orientam o treinamento das redes neurais, pois o objetivo do aprendizado é minimizar essa perda ajustando pesos e bias. A seguir estão três funções comuns.

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Funções de Erro

RMSE (Root Mean Squared Error)

O RMSE é muito usado em problemas de regressão, onde o objetivo é prever valores numéricos contínuos.

A fórmula é:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

onde: y_i = valor real

$\hat{y}_i$ = valor previsto pelo modelo

n = número de exemplos

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Funções de Erro

Binary Cross-Entropy (Binary Entropy Loss)

A binary cross-entropy é usada em classificação binária, quando a saída representa a probabilidade de uma classe (geralmente usando função sigmoid).

A fórmula é:
$$L = -\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

onde: $y_i \in \{0, 1\}$ é o rótulo verdadeiro
 $\hat{y}_i$ é a probabilidade prevista para a classe 1

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Funções de Erro

Cross-Entropy (para classificação)

A cross-entropy é uma generalização usada em classificação com várias classes (multiclasse), normalmente junto com a função softmax.

A fórmula geral é:
$$L = - \sum_{i=1}^C y_i \log(\hat{y}_i)$$

onde: C = número de classes

y_i = vetor de rótulo verdadeiro (geralmente one-hot)


$\hat{y}_i$ = probabilidade prevista para cada classe

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Função Softmax

Em redes neurais, especialmente em classificação, os termos **scores** e **logits** se referem aos valores brutos produzidos pela última camada do modelo antes de aplicar uma função de normalização, como Softmax.



Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Função Softmax

A função **softmax** é usada em redes neurais para **converter um vetor de valores reais** (scores ou logits) em uma **distribuição de probabilidades** sobre várias classes.

Visão Computacional e IA Generativa


2 - Fundamentos de Deep Learning

Função Softmax

Dado um vetor de entradas $z=(z_1, z_2, \dots, z_c)$, onde C é o número de classes, a função softmax é definida como:

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^C e^{z_j}}$$

Ex: $z = [4.0, 2.0, 0.2]$
 $\text{softmax}(z) = [0.66, 0.24, 0.1]$



Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Otimizador

Conceito

O otimizador é o algoritmo que será usado no treinamento para atualizar os pesos da rede neural, com base no gradiente da função de perda.




Um dos mais conhecidos é o Adam (Adaptive Moment Estimation).

O principal parâmetro que precisa ser informado é a taxa de aprendizado (learning rate).

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning




Outras Funções de Ativação



Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning


Outras Funções de Ativação




Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Dropout



(a) Standard Neural Net



(b) After applying dropout.

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Redes Neurais Convolucionais


As redes neurais convolucionais (CNNs) são arquiteturas de rede mais complexas que as MLPs (Multilayer Perceptrons), projetadas para aproveitar correlações de vizinhança dos dados de imagens.

Entretanto, ambas aprendem ajustando pesos e bias por meio de backpropagation e SGD. A principal diferença entre elas está na forma como os dados são conectados e nas operações realizadas nas camadas.

Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning


Redes Neurais Convolucionais



Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning


Redes Neurais Convolucionais



Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Exemplos de arquitetura CNN (AlexNet)



Visão Computacional e IA Generativa

2 - Fundamentos de Deep Learning

Exemplos interativos:

- <https://playground.tensorflow.org/>
- <https://www.nn-visual.com/>
- <https://poloclub.github.io/cnn-explainer/>



IBMEC.BR

 /IBMEC

 IBMEC

 @IBMEC_OFICIAL

 @IBMEC

 **ibmec**