

Curso de Ciência de Dados, Machine Learning, Deep Learning e IA generativa com uso de LLMs

Disciplina: Visão Computacional e IA Generativa

Professor(a): João Macedo

Visão Computacional e IA Generativa

3 - IA Generativa

Entender o que são modelos generativos

Diferenciar modelos generativos vs discriminativos

Conhecer o framework conceitual de modelos generativos

Introdução aos conceitos probabilísticos fundamentais

Visão geral das principais famílias de modelos generativos

Visão Computacional e IA Generativa

3 - IA Generativa

Definição

- Modelagem generativa é um ramo do aprendizado de máquina que treina um modelo para produzir novos dados semelhantes aos dados de treinamento.

Visão Computacional e IA Generativa

3 - IA Generativa

Ideia principal

➤ Treinar um modelo que aprenda como os dados são distribuídos.

Exemplo:

Treinar um modelo com imagens de cavalos para gerar novas imagens de cavalos que nunca existiram.

Visão Computacional e IA Generativa

3 - IA Generativa


Pipeline típico:

1. Dataset de treinamento
2. Treinamento do modelo
3. Amostragem (sampling)
4. Geração de novos dados

Visão Computacional e IA Generativa

3 - IA Generativa

Treinar um modelo para produzir novos dados que sejam estatisticamente indistinguíveis do conjunto original. O foco não é a memorização determinística, mas o mapeamento probabilístico.



Visão Computacional e IA Generativa

3 - IA Generativa

Conceitos importantes:

- Observação: Um exemplo do dataset
- Features: Características da observação

Visão Computacional e IA Generativa

3 - IA Generativa

Conceitos importantes:

- Modelos generativos precisam ser probabilísticos.

Por quê?

Queremos gerar variações diferentes.

Se fosse determinístico: sempre produziria a mesma saída.

ruído aleatório + modelo aprendido → nova amostra

Visão Computacional e IA Generativa

3 - IA Generativa

Modelos Discriminativos

➤ “A qual classe esse dado pertence?”

Exemplo: Data uma imagem Imagem → “é cachorro ou cavalo?”

Visão Computacional e IA Generativa

3 - IA Generativa

Modelos Generativos

- “Como gerar novos dados parecidos com esse conjunto?”

Exemplo: Gerar nova imagem de um cavalo.

Visão Computacional e IA Generativa

3 - IA Generativa

Diferença Matemática

Modelo **Discriminativo**: estima $p(y | x)$


Traduzindo: qual a probabilidade da imagem ter rótulo y (ex: cavalo) dada uma observação x (imagem de entrada)

Visão Computacional e IA Generativa

3 - IA Generativa

Diferença Matemática

Modelo **Discriminativo**:



Visão Computacional e IA Generativa

3 - IA Generativa

Diferença Matemática

Modelo **Generativo**: estima $p(x)$

O modelo é treinado para "aprender" a distribuição dos dados.


Permite gerar novos exemplos a partir da amostragem da distribuição.

Visão Computacional e IA Generativa

3 - IA Generativa

Diferença Matemática

Modelo **Generativo**:



Visão Computacional e IA Generativa

3 - IA Generativa

Diferença Matemática

Modelo **Generativo Condicional**: estima $p(\mathbf{x}|\mathbf{y})$

O modelo é treinado para "aprender" a distribuição dos dados de um dataset de um rótulo y específico (condicionada por classe).

Permite gerar novos exemplos de uma classe específica a partir da amostragem da distribuição.

Visão Computacional e IA Generativa

3 - IA Generativa

Por que Modelos Generativos são Difíceis?

Gerar dados é muito mais difícil do que classificá-los.

Compare a dificuldade das tarefas:

Diga se essa pintura é de Van Gogh?

ou...

Pinte uma nova obra no estilo Van Gogh.

Visão Computacional e IA Generativa

3 - IA Generativa

Framework de Modelagem Generativa

① Dataset de observações X

② Suposição de uma distribuição real: p_{data}

③ Construção de um modelo: p_{model} (para *imitar* p_{data})

Objetivo: $p_{\text{model}} \approx p_{\text{data}}$

Assim podemos amostrar novos dados.

Visão Computacional e IA Generativa

3 - IA Generativa


Propriedades de um bom modelo generativo p_{model}

- ① Acurácia (amostra c/ p_{model} alta deve parecer uma amostra de p_{data})
- ② Geração de novas imagens fácil
- ③ Representação (possibilidade de entender como características de alto nível dos dados são representadas em p_{model})

Visão Computacional e IA Generativa

3 - IA Generativa

Propriedade de um bom modelo generativo



Visão Computacional e IA Generativa

3 - IA Generativa

Aprendizado de representações

Dados reais são altamente dimensionais.

Exemplo: Imagem $256 \times 256 \rightarrow$ 65 mil pixels.

Modelos aprendem uma representação latente:

Imagem do dataset $\triangleright$ vetor latente $\triangleright$ Imagem reconstruída

Visão Computacional e IA Generativa

3 - IA Generativa

Aprendizado de representações

Imagem do dataset ➤ vetor latente ➤ Imagem reconstruída

Isso permite:


- manipular atributos
- gerar novos exemplos

Visão Computacional e IA Generativa

3 - IA Generativa

Aprendizado de Representação & Espaço Latente

Em vez de aprender a cor de milhões de pixels, a rede descobre dimensões subjacentes (ex: altura e largura de um objeto).



Visão Computacional e IA Generativa

3 - IA Generativa

Conceitos probabilísticos importantes

- Espaço amostral (todos valores possíveis)
- Função de densidade de probabilidade (*PDF* ou FDP)
- Modelo paramétrico θ
- Likelihood (Verossimilhança) - quão bem o modelo explica os dados?
- Maximum Likelihood Estimation (MLE) - método p/ encontrar melhores parâmetros θ

Visão Computacional e IA Generativa

3 - IA Generativa

Conceitos probabilísticos importantes

- Espaço amostral (todos valores possíveis)

Conjunto completo de valores que uma observação x pode ter.

Ex: - qualquer coordenada x, y

Visão Computacional e IA Generativa

3 - IA Generativa

Conceitos probabilísticos importantes

- Função de densidade de probabilidade (*PDF* ou FDP)

É uma função $p(x)$ que mapeia um ponto x no espaço amostral para um número entre 0 e 1. A integral da PDF sobre todos pontos é igual a 1.

Embora só exista uma PDF p_{data} , existem infinitas PDFs p_{data} que podemos usar para estimar p_{data} .

Visão Computacional e IA Generativa

3 - IA Generativa

Conceitos probabilísticos importantes

➤ Modelo paramétrico θ

É uma técnica que podemos usar para estruturar a busca por um $p_{model}(x)$ adequado.

Um modelo paramétrico é uma família de PDFs $p_{\theta}(x)$ ou $p(x | \theta)$ que podem ser descritas com um número finito de parâmetros θ .

Visão Computacional e IA Generativa

3 - IA Generativa

Conceitos probabilísticos importantes

- Likelihood (Verossimilhança) - quão bem o modelo explica os dados?

A Verossimilhança $L(\theta \mid \mathbf{x})$ de um conjunto de parâmetros θ é uma função que mede a plausibilidade de θ , dada uma observação $\mathbf{x}$.

$$L(\theta \mid \mathbf{x}) = p_{\theta}(\mathbf{x})$$

Visão Computacional e IA Generativa

3 - IA Generativa

Conceitos probabilísticos importantes

- Likelihood (Verossimilhança) - distinguindo de Probabilidade

Probabilidade $p(\mathbf{x}|\theta)$: você conhece os parâmetros (o "padrão") e quer saber a chance de observar determinados dados. Você olha do modelo para os dados.

Verossimilhança $L(\theta|\mathbf{x})$: você já tem os dados (as imagens, os números) e quer saber quão "verossímil" é que um determinado parâmetro θ tenha gerado esses dados. Você olha dos dados para o modelo.

A probabilidade se refere aos dados, a verossimilhança se refere aos parâmetros.

Visão Computacional e IA Generativa

3 - IA Generativa

Conceitos probabilísticos importantes

- Likelihood (Verossimilhança) - distinguindo de Probabilidade

Probabilidade $p(x|\theta)$: Suponha uma moeda com probabilidade de cara $\theta = 0,7$.

Se observarmos 3 caras em 5 lançamentos:

$$p(x = 3|\theta = 0.7) = \binom{5}{3} (0.7)^3 (0.3)^2$$

Aqui queremos **a probabilidade de um resultado específico** sabendo o parâmetro.

obs: a fórmula usada acima é a da PDF da distribuição binomial

Visão Computacional e IA Generativa

3 - IA Generativa

Conceitos probabilísticos importantes

- Likelihood (Verossimilhança) - distinguindo de Probabilidade

Verossimilhança $L(\theta|x)$: Observamos **3 caras em 5 lançamentos**.

A likelihood é:

$$L(\theta|x = 3) = \binom{5}{3} \theta^3 (1 - \theta)^2$$

Visão Computacional e IA Generativa

3 - IA Generativa

Conceitos probabilísticos importantes

➤ Likelihood (Verossimilhança)

Verossimilhança $L(\theta|x)$

Se tivermos um dataset $\mathbf{X}$ de diversos pontos x_i , a verossimilhança será o produtório

$$L(\theta|\mathbf{X}) = \mathbf{p}_{\theta}(x_1) \times \mathbf{p}_{\theta}(x_2) \times \dots \times \mathbf{p}_{\theta}(x_n)$$

O objetivo aqui é avaliar o modelo para os dados.

Visão Computacional e IA Generativa

3 - IA Generativa

Conceitos probabilísticos importantes

➤ Maximum Likelihood Estimation (MLE)

É a técnica que permite estimar o θ_e mais provável de explicar um dataset $\mathbf{X}$.

Para isso, é preciso obter o valor máximo de $L(\theta|\mathbf{X}) = \mathbf{p}_\theta(x_1) \times \mathbf{p}_\theta(x_2) \times \dots \times \mathbf{p}_\theta(x_n)$

Ocorre que produto de termos entre 0 e 1 pode ficar difícil computacionalmente, por isso frequentemente usamos a log-verossimilhança (**log-likelihood**):

$$\ell(\theta|\mathbf{X}) = \log(L(\theta|\mathbf{X})) = \log(\mathbf{p}_\theta(x_1)) + \log(\mathbf{p}_\theta(x_2)) + \dots + \log(\mathbf{p}_\theta(x_n))$$

Visão Computacional e IA Generativa

3 - IA Generativa

Conceitos probabilísticos importantes

➤ Maximum Likelihood Estimation (MLE)

A MLE portante tenta maximizar $\ell(\theta|\mathbf{X})$, o que pode ser formalizado como:

$$\theta_e = \arg_{\mathbf{x}} \text{max}(\ell(\theta|\mathbf{X}))$$

Resolvendo o exemplo anterior: $L(\theta) = 10\theta^3(1-\theta)^2 \gg$ queremos achar o valor máximo.

Então, **maximizamos o log da likelihood**: $\ell(\theta) = \log(L(\theta)) = \log 10 + 3\log\theta + 2\log(1-\theta)$.

Derivando: $d\ell/d\theta = 3/\theta - 2/(1-\theta)$ Fazendo $d\ell/d\theta = 0$, achamos $\theta = 0.6$


Redes neurais normalmente **minimizam** funções de erro. Então minimizamos a negativa da log-likelihood: $\theta_e = \arg_{\mathbf{x}} \text{min}(-\ell(\theta|\mathbf{X}))$

Visão Computacional e IA Generativa

3 - IA Generativa

Fundamentos Matemáticos: Espaço Amostral e FDP

Todo o universo de dados possíveis mapeado como um terreno de probabilidades.



Visão Computacional e IA Generativa

3 - IA Generativa

Variational Autoencoders (VAE)

- Entender autoencoders
- Entender espaço latente
- Compreender limitações dos autoencoders
- Entender variational autoencoders
- Explorar geração de imagens com VAE

Visão Computacional e IA Generativa

3 - IA Generativa

Variational Autoencoders (VAE)

- Modelos generativos aprendem a distribuição dos dados.

$$p_{\text{model}} \approx p_{\text{data}}$$

Visão Computacional e IA Generativa

3 - IA Generativa

Variational Autoencoders (VAE)

➤ Aplicações:

geração de imagens

geração de texto

criação de música

síntese de voz

Visão Computacional e IA Generativa

3 - IA Generativa

Autoencoders

➤ é uma rede neural que aprende a

- comprimir os dados
- reconstruir os dados

imagem ➤ encoder ➤ espaço latente ➤ decoder → img. reconstruída

Visão Computacional e IA Generativa

3 - IA Generativa

Autoencoders (componentes / estrutura)

➤ Encoder

transforma imagem em um **vetor latente z**

Visão Computacional e IA Generativa

3 - IA Generativa

Autoencoders (componentes / estrutura)


➤ Decoder

transforma **vetor latente z** em uma imagem (reconstrução)

Visão Computacional e IA Generativa

3 - IA Generativa

Autoencoders (arquitetura)



Visão Computacional e IA Generativa

3 - IA Generativa

Autoencoders (arquitetura)

Layer (type)	Output shape	Param #
InputLayer	(None, 32, 32, 1)	0
Conv2D	(None, 16, 16, 32)	320
Conv2D	(None, 8, 8, 64)	18,496
Conv2D	(None, 4, 4, 128)	73,856
Flatten	(None, 2048)	0
Dense	(None, 2)	4,098

Layer (type)	Output shape	Param #
InputLayer	(None, 2)	0
Dense	(None, 2048)	6,144
Reshape	(None, 4, 4, 128)	0
Conv2DTranspose	(None, 8, 8, 128)	147,584
Conv2DTranspose	(None, 16, 16, 64)	73,792
Conv2DTranspose	(None, 32, 32, 32)	18,464
Conv2D	(None, 32, 32, 1)	289

Visão Computacional e IA Generativa

3 - IA Generativa

Autoencoders (Codificação e Decodificação)


Codificação (Encoding) é a geração de **embedding** (**vetor latente z**) a partir da imagem (input)

Decodificação (Decoding) é a reconstrução da **imagem** (input) a partir do **vetor latente z** (**embedding**)

Visão Computacional e IA Generativa

3 - IA Generativa

Autoencoders (Codificação e Decodificação)




Visão Computacional e IA Generativa

3 - IA Generativa

Autoencoders

Visualizando o
espaço latente




Visão Computacional e IA Generativa

3 - IA Generativa

Autoencoders

Visualizando o
espaço latente





Visão Computacional e IA Generativa

3 - IA Generativa

Autoencoders

Amostragem e
reconstrução



Visão Computacional e IA Generativa

3 - IA Generativa

Autoencoders (treinamento)

O processo de aprendizado consiste em minimizar o erro de reconstrução (reconstruction loss).

O objetivo é fazer com que a imagem reconstruída seja semelhante à imagem original (input)

Visão Computacional e IA Generativa

3 - IA Generativa

Autoencoders (treinamento)

Loss Function

A função de perda (loss function) em um autoencoder tem como objetivo principal garantir que a saída da rede seja o mais próxima possível da entrada original. Normalmente denominado de **Erro de Reconstrução**.

Visão Computacional e IA Generativa

3 - IA Generativa

Autoencoders (treinamento)

Loss Function (Erro de Reconstrução)

As duas escolhas mais comuns são:


- RMSE (Root Mean Squared Error) - penaliza erros de forma simétrica mas pode pixelizar a imagem
- Entropia Cruzada Binária (Binary Cross-entropy) - assimétrico, penaliza erros próximos de 0 ou 1 e pode borrar imagem (evitando pixelização)

Visão Computacional e IA Generativa

3 - IA Generativa

Autoencoders (problemas)

Todo o universo de dados possíveis mapeado como um terreno de probabilidades.



Visão Computacional e IA Generativa

3 - IA Generativa

Variational Auto Encoders (VAEs)



Procura resolver problema do Autoencoder puro, introduzindo um **espaço latente probabilístico**

Em vez de mapear uma imagem para um ponto apenas, procura mapear uma imagem para uma distribuição

Visão Computacional e IA Generativa

3 - IA Generativa

Variational Auto Encoders (VAEs)



Visão Computacional e IA Generativa

3 - IA Generativa

Variational Auto Encoders (VAEs)

Aqui entra: Distribuição Normal

Encoder aprende uma **média μ** e uma **variância σ^2** (**σ** é o desvio padrão)

notação: **$z \sim N(\mu, \sigma)$**

o espaço latente é modelado como uma **distribuição normal**
com media **μ** e variância **σ^2**

Visão Computacional e IA Generativa

3 - IA Generativa

Variational Auto Encoders (VAEs)

Distribuição Normal

Em uma dimensão, a PDF da distribuição normal é dada por:

$$f(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$\mathbf{z} \sim \mathbf{N}(\boldsymbol{\mu}, \boldsymbol{\sigma})$$

Visão Computacional e IA Generativa

3 - IA Generativa

Variational Auto Encoders (VAEs)


Distribuição Normal

A curva vermelha é a $N(0, 1)$, ou distribuição normal unitária.

Podemos amostrar qq. ponto z de uma distr. normal $N(\mu, \sigma)$ com a equação

$$z = \mu + \sigma \cdot \square$$

* com $\square$ amostrado de $N(0, 1)$



Visão Computacional e IA Generativa

3 - IA Generativa

Variational Auto Encoders (VAEs)

Distribuição Normal Multivariada

Para mais de uma dimensão, a PDF da distribuição normal é dada por:

Σ é a matriz de covariância

μ é o vetor de médias

$$f(x_1, \dots, x_k) = \frac{\exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^T \Sigma^{-1}(\mathbf{x} - \mu)\right)}{\sqrt{(2\pi)^k |\Sigma|}}$$

$$\mathbf{z} \sim \mathbf{N}(\mu, \Sigma)$$

Visão Computacional e IA Generativa

3 - IA Generativa

Variational Auto Encoders (VAEs)

Distribuição Normal Multivariada padrão

Uma distribuição normal padrão $N(\mathbf{0}, \mathbf{I})$ é uma distribuição multivariada com o vetor de médias 0 (ex: [0. 0. 0.]) e matriz de covariância igual a uma matriz identidade. Ex:

$$\begin{bmatrix} 1. & 0. & 0. \\ 0. & 1. & 0. \\ 0. & 0. & 1. \end{bmatrix}$$

Visão Computacional e IA Generativa

3 - IA Generativa

Variational Auto Encoders (VAEs)

$$\mathbf{z} \sim \mathbf{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

O encoder agora só precisaria mapear a entrada para dois vetores, um **vetor de médias** e um **vetor de variâncias**. Como variâncias são sempre positivas, e as redes neurais normalmente produzem saídas no intervalo $(-\infty, \infty)$, usamos na prática o **logaritmo das variâncias**.

Visão Computacional e IA Generativa

3 - IA Generativa

Variational Auto Encoders (VAEs)

$$\mathbf{z} \sim \mathbf{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

Em resumo, o encoder agora do VAE mapeia a entrada para dois vetores:

$\mathbf{z}_{\text{mean}}$

$\mathbf{z}_{\text{log_var}} * (\text{log da variancia})$

* no entanto, quando formos amostrar o espaço latente, precisaremos fazer a operação inversa do log

Visão Computacional e IA Generativa

3 - IA Generativa

Variational Auto Encoders (VAEs)

$$\mathbf{z} \sim \mathbf{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

Tendo os vetores $\mathbf{z_mean}$ e $\mathbf{z_log_var}$ (log da variancia),
como amostramos $\mathbf{z}$?

Visão Computacional e IA Generativa

3 - IA Generativa

Variational Auto Encoders (VAEs)

$$\mathbf{z} \sim \mathbf{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

Tendo os vetores $\mathbf{z_mean}$ e $\mathbf{z_log_var}$ (log da variancia),
como amostramos $\mathbf{z}$?

Relembrar que em uma dimensão, se temos um gerador de amostras da distribuição $\mathbf{N}(\mathbf{0}, \mathbf{1})$, ou distribuição normal unitária, podemos amostrar qq. ponto $\mathbf{z}$ de uma distr. normal

$\mathbf{N}(\boldsymbol{\mu}, \boldsymbol{\sigma})$ com a equação $\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \cdot \square$ - * com $\square$ amostrado de $\mathbf{N}(\mathbf{0}, \mathbf{1})$

Visão Computacional e IA Generativa

3 - IA Generativa

Variational Auto Encoders (VAEs)

$$\mathbf{z} \sim \mathbf{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

Tendo os vetores $\mathbf{z_mean}$ e $\mathbf{z_log_var}$ (log da variancia),
como amostramos $\mathbf{z}$?

Então, vamos obter $\mathbf{z}$ com: $\mathbf{z} = \mathbf{z_mean} + \mathbf{z_sigma} * \text{epilson}$

com: $\mathbf{z_sigma} = \exp(\mathbf{z_log_var} * 0.5)$

$$\text{epilson} \sim \mathbf{N}(\mathbf{0}, \mathbf{I})$$


Visão Computacional e IA Generativa

3 - IA Generativa

Variational Auto Encoders (VAEs)

$$\mathbf{z} \sim \mathbf{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

O encoder passa a gerar dois vetores:



Visão Computacional e IA Generativa

3 - IA Generativa

Variational Auto Encoders (VAEs)

$$\mathbf{z} \sim \mathbf{N}(\boldsymbol{\mu}, \boldsymbol{\sigma})$$

A técnica de amostragem usando epsilon é denominada de truque de reparametrização:

$$\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \boldsymbol{\epsilon}$$

onde:

$$\boldsymbol{\epsilon} \sim \mathbf{N}(0, 1) \quad (\text{truque de reparametrização})$$

Isso isola a aleatoriedade no $\boldsymbol{\epsilon}$

Visão Computacional e IA Generativa

3 - IA Generativa

Variational Auto Encoders (VAEs)

Loss Function

Nos VAEs, além do erro de reconstrução, utiliza-se também a Divergência de Kullback–Leibler (KL), que mede quanto a distribuição de probabilidade aprendida pelo encoder (definida por z_mean e z_log_var) difere de uma distribuição normal padrão.

(A KL-divergence atua como regularizador do espaço latente, tornando-o mais contínuo e simétrico em torno da origem (sem ele poderiam haver lacunas que dificultariam a geração de novas imagens).

Visão Computacional e IA Generativa

3 - IA Generativa

Variational Auto Encoders (VAEs)

Loss Function

Como agora estamos usando dois componentes na Loss Function:

- Erro de reconstrução,
- Divergência de Kullback–Leibler (KL).

Podemos calcular a função de perda somando os dois termos ou usando um fator de ponderação β para equilibrar os termos:

$$L = \beta \cdot ER + (1 - \beta) \cdot KLD$$

Visão Computacional e IA Generativa

3 - IA Generativa

Variational Auto Encoders (Arquitetura)

Layer (type)	Output shape	Param #	Connected to
InputLayer (input)	(None, 32, 32, 1)	0	[]
Conv2D (conv2d_1)	(None, 16, 16, 32)	320	[input]
Conv2D (conv2d_2)	(None, 8, 8, 64)	18,496	[conv2d_1]
Conv2D (conv2d_3)	(None, 4, 4, 128)	73,856	[conv2d_2]
Flatten (flatten)	(None, 2048)	0	[conv2d_3]
Dense (z_mean)	(None, 2)	4,098	[flatten]
Dense (z_log_var)	(None, 2)	4,098	[flatten]
Sampling (z)	(None, 2)	0	[z_mean, z_log_var]



IBMEC.BR

 /IBMEC

 IBMEC

 @IBMEC_OFICIAL

 @IBMEC

 **ibmec**