

Curso de Ciência de Dados, Machine Learning, Deep Learning e IA generativa com uso de LLMs

Disciplina: Visão Computacional e IA Generativa

Professor(a): João Macedo

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

Entender as GANs

Framework Conceitual

Interação dos Componentes


Treinamento

Dificuldades / limitações

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

Contexto



Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

GANs vs Autoencoders e VAEs

- GANs não utilizam reconstrução direta da entrada.
- Em vez disso, o gerador aprende a mapear vetores de ruído para imagens realistas, guiado pelo feedback do discriminador.
- É uma abordagem fundamentalmente diferente dos Autoencoders e VAEs.

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

Origem

- Paper “Generative Adversarial Nets”, Ian Goodfellow et al., publicado na conferência NeurIPS em 2014.
- Representou um ponto de virada na história dos modelos generativos.
- A inspiração surgiu numa noite no bar - discutindo um problema técnico de geração de imagens que exigiria gigabytes de dados por imagem. Goodfellow percebeu que não era um problema de programação, mas de design de algoritmo.

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

Ideia Central

- A ideia principal de uma Rede Adversária Gerativa (GAN) é uma competição ou "batalha" entre duas redes neurais adversárias: o gerador e o discriminador.
- O processo pode ser comparado a um jogo entre falsificador e detector de itens falsificados.

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

Ideia Central

- As GANs usam duas redes. Um gerador e um discriminador.
- O **Gerador**: Tem como objetivo converter ruído aleatório em observações que pareçam ter sido amostradas do conjunto de dados original. Ele tenta criar "falsificações" tão perfeitas que o discriminador não consiga distinguir do real.

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

Ideia Central

- As GANs usam duas redes. Um gerador e um discriminador.
- O **Discriminador (ou Crítico)**: Atua como um classificador que tenta prever se uma observação específica é real (vinda do dataset original) ou falsa (criada pelo gerador).

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

Ideia Central

- O segredo do sucesso das GANs reside no **treinamento alternado**.
- À medida que o gerador se torna mais habilidoso em enganar o discriminador, o discriminador precisa se adaptar para manter sua capacidade de identificar o que é falso.

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

Ideia Central

- Esse ciclo contínuo força o gerador a encontrar novas maneiras de produzir imagens cada vez mais realistas para continuar enganando seu adversário.
- Essa arquitetura tornou-se um marco no deep learning por ser capaz de gerar imagens significativamente mais nítidas e bem definidas do que outros modelos, como os Variational Autoencoders (VAEs).

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)


Ideia Central

- O termo adversarial ressaltava o aspecto de existir uma batalha entre dois adversários, o gerador e o discriminador. Ao final do processo de treinamento você terá duas redes, uma de geração de imagens e uma de discriminação.
- Uma pergunta comum: podemos usar uma GAN para treinar classificadores? Quais vantagens, desvantagens?

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

Visualização de uma GAN - Componentes



Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

Componentes de uma GAN

- **Discriminador:** A função do discriminador é predizer se uma imagem é verdadeira ou falsa. Pode-se usar uma arquitetura similar a de um classificador de imagens (ex: uma CNN), com uma saída 0 para imagens falsificadas e 1 para imagens verdadeiras.

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

Componentes de uma GAN

- **Gerador:** A função do gerador é gerar uma imagem semelhante a uma imagem real, com as mesmas dimensões da imagem do discriminador. O processo de geração parte de uma amostragem de um vetor z de uma distribuição normal multivariada $N(0, I)$.


* Essa definição é semelhante ao Decoder de um VAE.


** A ideia de mapear de um espaço latente para o domínio original (imagem) é recorrente na modelagem generativa (permite manipular vetores no espaço latente e alterar features no domínio original).

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

Visualização de uma GAN - Treinamento





Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

Variational Autoencoder (VAE)

- ✓ Encoder mapeia $x \rightarrow$ distribuição latente z
- ✓ Decoder reconstrói x a partir de z
- ✓ Loss = Reconstrução + KL Divergence
- ✓ Imagens tendem a ser mais borradas
- ✓ Treinamento estável e previsível
- ✓ Espaço latente contínuo e suave

Generative Adversarial Network (GAN)

- ⚖ Gerador mapeia ruído $z \rightarrow$ imagem
- ⚖ Discriminador julga real vs falso
- ⚖ Loss = Jogo adversário (min-max)
- ⚖ Imagens nítidas e bem definidas
- ⚖ Treinamento instável e delicado
- ⚖ Sem encoder — sem reconstrução

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

DCGAN - Deep Convolutional GAN

- **Paper:** Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks. Alec Radford et al. Jan, 2016, <https://arxiv.org/abs/1511.06434>.

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

DCGAN - Deep Convolutional GAN

Discriminador

- Input: Imagem 64×64 (1 canal)
- Conv2D com stride 2 → reduz resolução
- BatchNorm + LeakyReLU + Dropout
- Filtros: 64 → 128 → 256 → 512
- Sigmoid final → probabilidade [0, 1]
- Loss: Binary Cross-Entropy

Gerador

- Input: Vetor latente (dim=100)
- Conv2DTranspose → aumenta resolução
- BatchNorm + LeakyReLU
- Filtros: 512 → 256 → 128 → 64 → 1
- Tanh final → saída em [-1, 1]
- Loss: BCE (rótulo = 1 para fakes)

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

DCGAN - Treinamento

1. Treinar Discriminador

Imagens reais (label 1) + imagens geradas (label 0).
Calcular BCE loss e atualizar pesos do discriminador.

2. Treinar Gerador

Gerar batch de imagens a partir de ruído.
Passar pelo discriminador (pesos congelados).
BCE loss com label 1 → atualizar pesos do gerador.

3. Alternar

Repetir alternadamente, atualizando apenas um modelo de cada vez.
O equilíbrio é essencial — nenhum deve dominar.



Dica: Adicionar ruído aos labels (label smoothing) melhora a estabilidade — evita que o discriminador domine.

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

DCGAN - Dificuldades do Treinamento



Discriminador domina

Gradientes desaparecem, gerador para de aprender. Solução: aumentar dropout, reduzir learning rate do discriminador.



Mode Collapse

Gerador produz imagens muito similares, mapeando todo o espaço latente para poucos modos. Solução: fortalecer discriminador.



Loss não informativa

A loss do gerador pode aumentar mesmo com melhora na qualidade das imagens — dificulta o monitoramento do treinamento.



Sensibilidade a hiperparâmetros

Batch norm, dropout, learning rate, filtros, kernel size — pequenas mudanças podem desestabilizar completamente o modelo.

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

WGAN-GP - Wasserstein GAN com Gradient Penalty

- **Paper:** Wasserstein GAN. Martin Arjovsky et al. Jan, 2017, <https://arxiv.org/abs/1701.07875>.

Introduz Wasserstein Loss e Gradient Penalty
Surgiu como tentativa de estabilizar o treinamento
das GANs

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

WGAN-GP - Wasserstein Loss

Rótulos: 1 e -1

Em vez de 1 e 0, usamos 1 (real) e -1 (falso).

Sem sigmoid

O crítico não tem ativação sigmoid — saída livre em $(-\infty, +\infty)$.

Wasserstein Loss

Crítico: maximiza a diferença entre scores reais e falsos.
Gerador: maximiza o score das imagens geradas.

O Discriminador é substituído por um crítico

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

WGAN-GP - Wasserstein Loss

Fórmulas:

Crítico: $\min -E[D(x)] + E[D(G(z))]$ (maximizar diferença entre real e falso)

Gerador: $\min -E[D(G(z))]$ (maximizar score das fakes)

No Crítico: $D(x)$ - queremos D alto quando critica(avalua) imagem real x
 $D(G(z))$ - queremos D baixo (negativo) quando avalia imagem fake $G(z)$

No Gerador: $D(G(z))$ - queremos D alto quando avalia imagem fake $G(z)$

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

WGAN-GP - Wasserstein Loss

No Crítico: $D(x)$ - queremos D alto quando critica(avalua) imagem real x
 $D(G(z))$ - queremos D baixo (negativo) quando avalia imagem fake $G(z)$

No Gerador: $D(G(z))$ - queremos D alto quando avalia imagem fake $G(z)$

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

WGAN-GP - Gradient Penalty

A Wasserstein Loss tem uma implicação: o crítico pode gerar saídas entre $-\infty$ e $+\infty$, isso é um problema para redes neurais que precisam evitar explosões numéricas.

Inicialmente, foi utilizado um limite no gradiente dos pesos (por ex: limitando a um intervalo fixo, tipo $[-0.01, 0.01]$), o que criou outros problemas.

O Gradient Penalty substitui o *weight clipping* por uma restrição mais suave e teórica: em vez de limitar pesos, ele penaliza o norma do gradiente do critic.

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

WGAN-GP - Gradient Penalty

O Gradient Penalty substitui o *weight clipping* por uma restrição mais suave e teórica: em vez de limitar pesos, ele penaliza o norma do gradiente do critico.


Paper: Improved Training of Wasserstein GANs, Ishaan Gulrajani et al. Mar. 2017. <https://arxiv.org/abs/1704.00028>.

$$L = \underbrace{\mathbb{E}_{\tilde{x} \sim \mathbb{P}_g} [D(\tilde{x})] - \mathbb{E}_{x \sim \mathbb{P}_r} [D(x)]}_{\text{Original critic loss}} + \lambda \underbrace{\mathbb{E}_{\hat{x} \sim \mathbb{P}_{\hat{x}}} [(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2]}_{\text{Our gradient penalty}}. \quad (3)$$

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

WGAN-GP - Gradient Penalty



Restrição 1-Lipschitz: $|D(x_1) - D(x_2)| / |x_1 - x_2| \leq 1$

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

WGAN-GP - Resumo

- ✓ Wasserstein loss em vez de BCE
- ✓ Labels: 1 (real) e -1 (falso)
- ✓ Sem sigmoid na camada final do crítico
- ✓ Gradient Penalty na loss do crítico
- ✓ Treinar crítico 3-5× por atualização do gerador
- ✓ Sem Batch Normalization no crítico

Resultado: loss correlacionada com qualidade, treinamento mais estável, imagens mais nítidas.

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

CGAN - Condicional GANs


- **Paper:** Conditional Generative Adversarial Nets. Mehdi Mirza and Simon Osindero. Nov, 2014, <https://arxiv.org/abs/1411.1784>.

Tanto o gerador quanto o crítico recebem o label como entrada adicional.

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

CGAN - Condicional GANs



O label condiciona tanto o gerador quanto o crítico

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

CGAN - Condicional GANs

Gerador

Input = concat(z, label_one_hot)
Ex: vetor de 32 + label [0,1] = 34 dims

Crítico

Input = concat(imagem, label_channels)
Ex: imagem 64×64×3 + label 64×64×2 = 5 canais

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

CGAN - Condicional GANs

Por que funciona?

O crítico agora sabe qual label corresponde a cada imagem. Se o gerador produzir uma imagem perfeita mas que contradiga o label fornecido, o crítico detecta a inconsistência. Isso força o gerador a respeitar o condicionamento.

Exemplo: condicionar em 'cabelo loiro' — o gerador aprende a controlar apenas essa característica, mantendo o restante da face inalterado.

Visão Computacional e IA Generativa

4 - Redes Generativas Adversariais (GANs)

Resumo comparativo de GANs

Aspecto	DCGAN	WGAN-GP	CGAN
Loss	Binary Cross-Entropy	Wasserstein + GP	Wasserstein + GP
Discriminador	Sigmoid $\rightarrow [0,1]$	Sem sigmoid (crítico)	Sem sigmoid (crítico)
Labels	1 (real), 0 (falso)	1 (real), -1 (falso)	1 / -1 + label classe
BatchNorm	Sim (ambos)	Não no crítico	Não no crítico
Treinamento	1:1 (D:G)	3-5 : 1 (C:G)	3-5 : 1 (C:G)
Estabilidade	Baixa	Alta	Alta
Condicionamento	Não	Não	Sim (label input)

ibmec.br

ibmec



IBMEC.BR

 /IBMEC

 IBMEC

 @IBMEC_OFICIAL

 @IBMEC

 **ibmec**