

Curso de Ciência de Dados, Machine Learning, Deep Learning e IA generativa com uso de LLMs

Disciplina: Visão Computacional e IA Generativa

Professor(a): João Macedo

Visão Computacional e IA Generativa

6 - Yolo

- Introdução
- Métricas e conceitos
- Evolução
- YoloV8
- Prática

Visão Computacional e IA Generativa

6 - Yolo

Detecção como regressão direta

Uma única rede neural prediz bounding boxes e classes em uma só passagem (forward pass).

● Single-Shot

Detecta todos os objetos em uma única passagem pela CNN

● Visão Global

A rede processa a imagem inteira, reduzindo falsos positivos de background

● Ultra-Rápido

30-160+ fps dependendo da versão e hardware

● Multitarefa

Localização + Classificação + (Segmentação/Pose nas versões novas)

Antes do YOLO (R-CNN family)

- R-CNN: ~47 segundos / imagem
- Fast R-CNN: ~2 segundos
- Faster R-CNN: ~0.2s (5 fps)

Com YOLO

- YOLOv1: 45 fps (10× mais rápido!)
- YOLOv8n: 160+ fps em GPU moderna
- YOLO11: velocidade + precisão state-of-art
- Suporte: detecção, seg., pose, rastreamento

Visão Computacional e IA Generativa

6 - Yolo (entendendo métricas e conceitos de detecção de objetos)

Em um modelo típico de detecção de objetos, temos:

Entrada: Imagem

Saída:

- bounding boxes (caixas delimitadoras ou retângulos),
- rótulos de classe,
- scores de confiança

Visão Computacional e IA Generativa

6 - Yolo (entendendo métricas e conceitos de detecção de objetos)

Classe e confiança:

Para cada caixa, o modelo prevê:

- qual classe ela representa,
- quão confiante ele está nessa previsão

Esse score de confiança ajuda a filtrar resultados ruins. Por exemplo, você pode manter apenas detecções com confiança acima de 0,5.

Visão Computacional e IA Generativa

6 - Yolo (entendendo métricas e conceitos de detecção de objetos) IoU


IoU (**Intersection over Union**) mede o quanto a caixa prevista coincide com a caixa correta.

É uma métrica fundamental para avaliar se a localização do objeto ficou boa. Quanto maior o IoU, melhor o encaixe entre previsão e verdade de referência.

Visão Computacional e IA Generativa

6 - Yolo (entendendo métricas e conceitos de detecção de objetos)

IoU – Intersection over Union



$$\text{IoU} = \text{Área da Interseção} / \text{Área da União}$$

$\text{IoU} \geq 0.5$

TP (mAP@50)

$\text{IoU} \geq 0.75$

Critério rigoroso

$\text{IoU} < 0.5$

FP (falso positivo)

Visão Computacional e IA Generativa

6 - Yolo (entendendo métricas e conceitos de detecção de objetos) NMS

Quando o modelo prevê várias caixas parecidas para o mesmo objeto, entra o NMS (**Non-Maximum Suppression**).

Ele remove caixas redundantes e mantém a melhor. Esse passo deixa a saída final mais limpa e utilizável.

Visão Computacional e IA Generativa

6 - Yolo (entendendo métricas e conceitos de detecção de objetos) NMS

É uma etapa de pós-processamento usada depois que o modelo já gerou várias caixas candidatas.

A função dela é remover caixas duplicadas que apontam para o mesmo objeto. Em bibliotecas como torchvision, o NMS faz isso removendo iterativamente caixas com IoU acima do limiar em relação a uma caixa de score maior.

Visão Computacional e IA Generativa

6 - Yolo (entendendo métricas e conceitos de detecção de objetos) NMS

Objetivo:

Modelos como YOLO costumam prever muitas caixas parecidas para o mesmo objeto. Sem NMS, um único carro poderia aparecer 4 ou 5 vezes na saída final.

A documentação da Ultralytics descreve o NMS justamente como um filtro de caixas sobrepostas com base em confiança e IoU.

Visão Computacional e IA Generativa

6 - Yolo (entendendo métricas e conceitos de detecção de objetos) NMS

O NMS usa um IoU, que não é a mesma coisa que o IoU usado para avaliar o modelo contra o ground truth.

No NMS, o IoU compara caixas previstas entre si para remover duplicatas.

Na avaliação, o IoU compara caixa prevista vs. caixa correta para decidir qualidade da detecção.

Visão Computacional e IA Generativa

6 - Yolo (entendendo métricas e conceitos de detecção de objetos)

Precisão, Recall e F1-Score

Precisão (P)

$$TP / (TP + FP)$$

De tudo que foi detectado,
quanto estava certo?

Recall (R)

$$TP / (TP + FN)$$

De todos os objetos reais,
quantos foram encontrados?

F1-Score

$$2 \times P \times R / (P + R)$$

Média harmônica entre
Precisão e Recall

Visão Computacional e IA Generativa

6 - Yolo (entendendo métricas e conceitos de detecção de objetos)

mAP (Mean Average Precision) é a principal métrica de avaliação em detecção de objetos.

É a média das Average Precisions (AP) de todas as classes.

Calcula-se a curva Precision-Recall, depois calcula AP de cada classe, e por fim faz a média entre todas as classes.

1

Gerar Predições

Rodar o modelo sobre o dataset de validação com diferentes limiares de confiança

mAP@0.5 - IoU $\geq$ 0.50 (mais leniente)

2

Calcular P e R

Para cada limiar: verdadeiros/falsos positivos $\rightarrow$ Precisão e Recall

3

Curva P-R

Plotar Precisão $\times$ Recall para cada classe, ordena por recall crescente

4

AP por classe

Área sob a curva P-R (interpolação de 101 pontos no COCO)

5

mAP final

Média das APs de todas as N classes: $mAP = (1/N) \times \sum AP_i$

YOLOv8x: mAP@50-95 = 53.9 no COCO val

Visão Computacional e IA Generativa

6 - Yolo - Histórico

2015

Redmon et al.
Uni. of Washington

- Backbone: GoogLeNet modificado
- Grid: 7×7 células
- 2 bounding boxes / célula
- 20 classes (PASCAL VOC)
- 45 fps (fast: 155 fps!)
- Treinamento end-to-end

Inovação Principal

Reformulou detecção como um único problema de regressão. A imagem é dividida em uma grade $S \times S$ e cada célula prediz diretamente bounding boxes e probabilidades de classe.

Pontos Fortes

- Extremamente rápido
- Visão global da imagem
- Treinamento simplificado

Limitações

- Dificuldade com objetos pequenos
- Apenas 2 boxes por célula
- Precisão inferior ao Faster R-CNN

Visão Computacional e IA Generativa

6 - Yolo - Histórico

YOLOv2 / YOLO9000 - 2016

1**Anchor Boxes**

Caixas pré-definidas por k-means no dataset, melhorando recall

2**Batch Normalization**

Adicionado em cada camada convolucional (+2% mAP)

3**Multi-Scale Training**

Treina com imagens de 320–608px a cada 10 batches

4**Darknet-19**

Nova backbone 19 camadas, mais eficiente que GoogLeNet

5**YOLO9000**

Deteção de 9000 classes com hierarchical classification (WordNet)

YOLOv3 - 2018

1**Darknet-53**

Backbone com 53 camadas convolucionais e conexões residuais (ResNet-like)

2**3 Escalas de Detecção**

Predições em 3 níveis de resolução: 13×13, 26×26, 52×52

3**9 Anchor Boxes**

3 anchors por escala, permitindo detectar objetos de tamanhos variados

4**Logistic Regression**

Substituição da softmax por sigmoid para classificação multi-label

5**mAP 57.9%**

COCO - melhor equilíbrio entre velocidade e precisão da época

Visão Computacional e IA Generativa

6 - Yolo - Histórico

YOLOv4 – Bochkovskiy et al. 2020

1**CSPDarknet53**

Backbone com Cross Stage Partial connections – reduz cálculos

2**PANet**

Path Aggregation Network para melhor fusão de features multi-escala

3**Bag of Freebies**

Data augmentation avançado: CutMix, Mosaic, DropBlock

4**Bag of Specials**

Mish activation, SPP, SAM block para melhor precisão

5**mAP 43.5% COCO**

65.7 fps GPU Tesla V100 – melhor trade-off da época

YOLOv5 – Ultralytics 2020

1**PyTorch Nativo**

Primeira versão 100% em PyTorch – mais fácil de usar/modificar

2**Auto Anchor**

Geração automática de anchors adaptados ao dataset do usuário

3**4 Variantes**

n/s/m/l/x – de ultrarrápido a máxima precisão

4**Export Flexível**

ONNX, TFLite, CoreML, TensorRT – deploy em qualquer plataforma

5**Comunidade Enorme**

50k+ stars GitHub, documentação excelente, Ultralytics HUB

Visão Computacional e IA Generativa

6 - Yolo - Histórico

YOLOv6 2022 - Meituan	YOLOv7 2022 - Wang et al.	YOLOv8 2023 - Ultralytics
EfficientRep Backbone baseado em RepVGG com re-parametrização	E-ELAN Extended ELAN para melhor gradiente no backbone	C2f Block Gradiente rico com conexões cross-stage aprimoradas
Anchor-Free Elimina anchors pré-definidas, simplificando treino	Aux. Head Treinamento com cabeça auxiliar, removida no teste	Decoupled Head Cabeças separadas para classificação e regressão
BiC Module Bi-directional Concatenation para melhor neck	Re-param Re-parametrização de convoluções para inferência	Anchor-Free Task-Aligned Assigner para matching dinâmico
Foco Industrial Otimizado para edge devices e produção	SOTA 2022 Maior mAP com menor custo computacional da época	5 Tarefas Detect, Segment, Pose, Classify, OBB (oriented)

Visão Computacional e IA Generativa

6 - Yolo - Histórico

YOLOv9

Wang et al. - Fev/2024

- GELAN - Generalized Efficient Layer Aggregation Network
- PGI - Programmable Gradient Information para evitar perda de info
- Resolve o 'information bottleneck' em redes profundas
- mAP 55.6% COCO com menor parâmetros que YOLOv8

YOLOv10

Tsinghua - Mai/2024

- NMS-Free: eliminação do Non-Maximum Suppression em inferência
- Dual-Label Assignment: consistência pós-treinamento sem NMS
- Cabeças eficientes com separação rank-guided
- Latência reduzida para aplicações de borda (edge)


YOLO11

Ultralytics - Out/2024

- C3k2 Block: substituição do C2f com melhor eficiência
- SPFF: Spatial Pyramid Pooling aprimorado
- Melhor precisão com menos parâmetros que YOLOv8
- Suporte nativo: OBB, Pose, Track, Segment, Classify

Visão Computacional e IA Generativa

6 - Yolo - Histórico



Visão Computacional e IA Generativa

6 - YoloV8 - Visão Geral



Visão Computacional e IA Generativa

6 - YoloV8 - BackBone CSPDarknet com bloco C2f C2f

Objetivo:


É um bloco da arquitetura do YOLOv8 usado para processar e combinar mapas de características.

Versão mais rápida (f) do bloco C2 que substituiu o bloco C3 do YoloV5.

Visão Computacional e IA Generativa

6 - YoloV8 - BackBone CSPDarknet com bloco C2f

Bloco C2f (Cross Stage Partial + Bottleneck)



n = número de bottlenecks (varia por variante)

Características do bloco C2f

Gradiente Rico

Conexões cross-stage permitem gradientes fluírem por caminhos mais curtos, facilitando o aprendizado

Reutilização de Features

Concatenação de múltiplas saídas intermediárias aumenta riqueza de representação

Eficiência

Reduz parâmetros e FLOPs mantendo representação expressiva vs. CSP original

Escalabilidade

4 variantes (n/s/m/l/x): o 'n' do C2f controla a profundidade


Variantes: YOLOv8n · s · m · l · x (crescente em parâmetros, precisão e custo computacional)

Visão Computacional e IA Generativa

6 - YoloV8 - Neck (FPN+PAN) e Head Desacoplado

Neck: FPN + PAN (Feature Pyramid + Path Aggregation)

Top-Down (FPN)



Bottom-Up (PAN)

O PAN complementa o FPN propagando informação de localização (bottom-up) combinando com semântica (top-down). Resultado: features ricas em todas as escalas.

Head Desacoplado (Decoupled Head)

YOLOv8 separa completamente as tarefas de classificação e regressão:

Cls Branch

Conv → Conv → Sigmoid
Prediz: probabilidade de classe

Reg Branch

Conv → Conv → DFL
Prediz: (l, t, r, b) distribuição

Distribution Focal Loss (DFL)

Em vez de prever (x,y,w,h) diretamente, o DFL prediz uma distribuição de probabilidades sobre possíveis distâncias da borda, aumentando precisão de localização.

Visão Computacional e IA Generativa

6 - YoloV8 - Prática

Python

```
# Instalação
uv pip install ultralytics

# Importar e carregar modelo
from ultralytics import YOLO

model = YOLO('yolov8n.pt') # baixa auto.
# Modelos: n, s, m, l, x
```

Python

```
# Inferência em imagem
results = model('imagem.jpg')
```

Python

```
# Processando resultados
for result in results:
    boxes = result.boxes # bbox
    masks = result.masks # segm.
    keypoints = result.keypoints

    for box in boxes:
        cls = int(box.cls[0])
        conf = float(box.conf[0])
        xyxy = box.xyxy[0].tolist()
        name = result.names[cls]
        print(f'{name}: {conf:.2%}')
```



IBMEC.BR

 /IBMEC

 IBMEC

 @IBMEC_OFICIAL

 @IBMEC

 **ibmec**